10.3第四批人工体验验收

2. 做聊天页 UI01–UI07

3. 工作台恢复后做 RG01–RG04

【重要】工作台界面改造

2. 做聊天页 UI01—UI07

打开聊天页，准备Nbal_out.xls 原件 (data/raw/whcns/received–2026–09–26/package/模型/Nbal_out.xls)。服务重启后要重新上传附件。

- UI01—UI04： 连续提两个文献问题，向上读旧回答，再点“最新消息”；试中文输入、Enter 换行、Ctrl/Cmd＋Enter 发送和“新对话”；检查标题、列表、窄窗口排版及“复制回答”；点击回答中的 [1] 阅读完整摘录、返回回答，再提一问确认引用只定位到所属轮次。
- UI05： 拖入原件，观察上传进度和“待分析→可分析”，问“硝态氮最大值及日序”。核对回答中的记录数、单元格证据，以及最大值约 3.6593、日序 283。
- UI06： 移除附件后问“那最小值呢”，确认系统没有沿用旧附件数值；重新上传原件，明确问最小值，核对 0、首次日序 2、并列 191 次。
- UI07： 试选 PDF 或一次拖入两个文件，检查错误提示；提文献问题时观察等待计时。若实际遇到网络错误，点“重试”并检查用户问题未重复；没有遇到就记“本次未复现”。

每项的预期和结果栏都在11 项验收清单 (docs/iterations/2026–09–29–agent–harness/acceptance–04.md)，这部分预计 20—30 分钟。

3. 工作台恢复后做 RG01—RG04

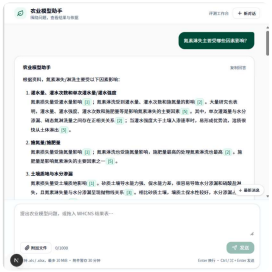
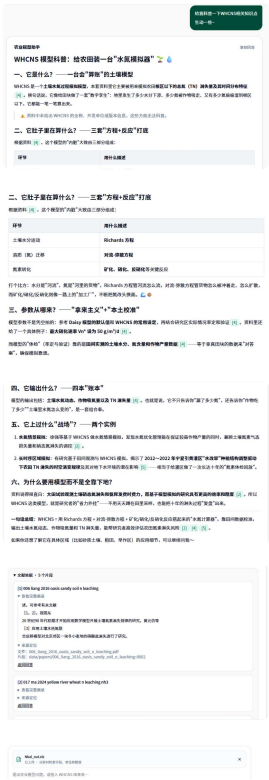
```
从本机凭据文件 (backend/var/eval/access-credentials.txt)取 local-developer 密钥登录工作台，不要把密钥写进验收记录。

1. RG01： 选择 F05 v2 →“新建一次执行”→上传原件→发送最大值问题→追问“那最小值呢”→填写标题并点“保存为回归基线”。确认两轮、附件事件和构建版本都保存。
2. RG02： 对该基线点“用当前版本重跑”，完成后点“比较结果”。逐轮查看左右两侧的回答、证据、路由、工具、版本和耗时；确认旧执行仍在。
3. RG03： 点“打开新执行 / 人工评分”，核查实际结果后提交新评分，再打开比较。确认新旧评分独立，未评分项没有自动变成通过。
4. RG04： 另建执行，提问后添加“手动操作备注”，保存基线并重跑。确认页面显示“受阻”，没有跳过人工步骤或生成通过评分。
```

计划日期：2026–09–30，约 20—30 分钟。自动验证已完成；下列人工验收保持待办。
专业结论仍按 10 项专业审核清单 单独审核。

入口：聊天 · 评测工作台。
工作台开发者密钥在本机 `backend/var/eval/access-credentials.txt` 。

附件使用已提供的 `Nbal_out.xls` 原件：`data/raw/whcns/received-2026-09-26/package/模型/Nbal_out.xls` 。

项目	操作	应看到的结果	人工结果
UI01 聊天布局	连续提问，向上查看旧回答，再点“最新消息”	顶部导航和底部输入可用；向上阅读不被新消息强行拉回	已验收。基本符合预期 
UI02 输入与新对话	中文输入、Enter 换行、Ctrl/Cmd + Enter 发送；点“新对话”	输入法选词不误发；新对话清空消息、草稿和附件	已验收。基本符合预期 能够实现基础的中文输入和换行操作，能够在新对话里实现清空对话框内草草稿和附件、以及清空历史消息 【关键问题】：进入新对话后，在对话框内输入内容无法正常发送，无法对话 

UI03 回答排版与复制	问文献问题，阅读标题、列表等；复制回答	Markdown 可读；复制内容完整；窗口收窄无整体横向溢出	已验收。基本符合预期 支持md可读，支持窗口变化前端正常展示，支持复制粘贴。 【重要问题：多次复制按钮的变化】 现状：只有首次复制后，转化为复制成功按钮，如果二次复制，则按钮始终为已复制状态，用户感知不到二次复制是否是复制成功。 期望：参考gpt逻辑。 1．复制按钮逻辑为：点击复制按钮–>按钮转化为【复制成功】or【对勾】–>1sor2s后恢复原状态–>满足下一次复制条件。图示为gpt逻辑，可以做重点参考  2．【长期工作】期望增加正向or负向评价按钮，期望未来与工作台打通，我们可以针对用户打的负向对话来重点做改进

UI04 引用定位	点击回答中的 [1]，展开完整摘录及来源定位，再返回回答；另提一问重复	定位同一轮对应引用，不跳到其他轮；片段和文件信息可读	已验收。基本符合预期。 值得改造的点，如下： 1. 用户侧：认为不需要向用户透传具体的命中哪一个切片。 2. 【期望向用户展示的真正内容】： a. 颗粒度为文章。 b. 不需要告诉该文章在库里的编号 3. 后台侧：认为命中的的切片内容，可以告知给内部人员协助来做判断。这块逻辑后续可以做细化。

UI05 附件状态	拖入 Nbal_out.xls，再问“硝态氮最大值及日序”	上传进度→待分析→可分析；回答含记录数及单元格证据；最大值约 3.6593，日序 283	已验收。基本符合预期。 现已支持拖拽上传文件，和点击按钮上传文件。 【重要问题】如下： 1. 类似问题回答不出来： a.  该案例中问题为：分析下硝态氮最大值及日序，就会回答出来了。 b. 期望类似问题，分析识别完用户意图后，若符合【硝态氮最大值及日序】条件，则返回对应数值。 c. 逻辑为：【理解用户意图】–>【意图包含使用whcns来理解表格文件】–>【调用对应的whcns skill】–>【返回skill结果以及对结果的解释（目前缺少）】 2. 对外透传规则 a. 现状：  b. 复核信息这块内容：不建议向用户透传，只建议向工作

			台，内部人员侧，进行透传 c. 并且复核信息里的这块内容，他的含义是什么？一串乱码，能帮助我们理解什么呢。

UI06 附件替换与移除	移除附件后问“那最小值呢”；再上传原件并明确问最小值	无附件时不沿用旧数值；重新分析返回最小值 0、首次日序 2、并列 191 次	已验收。不合预期。 【重要】期望如下： 1. 【附件】：附件随对话发出后，则不会在下一轮对话里出现，认为已上传至系统中。如果用户未来询问与已上传过的文件有关。则查上下文找到过去曾上传过的文件，再进行进一步处理 2. 【逻辑】： a. 该轮用户选择了上传文件，认为问题与文件强相关：【分析问题】–>【识别文件】–>【给出回答】 b. 该轮用户不上传文件：【分析问题】–>【识别到用户问题涉及到文件】–>【查上下文是否有文件】–>【如有则验证该文件是否是用户需要的】–>【走文件相关流程】

UI07 上传错误与等待	选择 PDF 或一次拖入两文件；文献提问观察等待状态	明确显示格式/单文件限制；等待显示耗时；出现网络错误时可重试且不重复用户问题	已验收。部分符合预期。 改进点如下： 1. 【应支持多文件上传】： a. 允许多文件上传 b. 每个文件都支持显示对应信息， c. 可以参考gpt 
RG01 冻结基线	开发者登录，选 F05 v2，新建执行，上传原件，问最大值后追问“那最小值呢”；保存基线	两轮、附件事件及构建版本保存；不要求先编造评分	已验收。基本通过
RG02 自动重跑与比较	对 RG01 点“用当前版本重跑”，完成后“比较结果”	新执行按原顺序运行；左右展示两轮回答、证据、路由、工具、版本和耗时差；旧记录保留	已验收。基本通过 改进点： 1. ui上可以调整一下，冻结基线和当前重跑并非左右，相对来说会有点乱
RG03 独立评分	打开新执行，核查后提交评分，再打开比较	新评分独立保存；原评分不变；未评分状态不被自动计为通过	已验收。基本通过 改进点： 1. 异常问题： a. 异常问题报错是正常的。 b. 异常问题显示在页面顶部，需要调整。期望展示在提交评分按钮周围，便于理解。

RG04 不可自动复现	另建执行提问后添加“手动操作备注”，保存基线并重跑	明确显示受阻，不跳过人工步骤，也不生成通过评分	已验收。基本通过 改进点： 1. 现在在单个执行内，只要某一轮存在手动操作备注，则整体都需要手动执行 a. 期望更智能的做法，比如第四轮才是手动操作时，期望能跑完前三轮，再报受阻

UI04 的引用只是阅读定位；本轮没有新增 PDF 在线预览或自动页码识别。
UI07 的慢请求/错误依赖实际网络；不方便重现时写“本次未复现”，自动用例已检查失败重试。
同版本文件计算应稳定；模型回答存在随机性，差异本身不等于质量下降或上升。
跨版本对照需保留基线数据库，并在更新代码后配置新的构建标识重新启动。

记录问题时附：项目编号、操作步骤、问题原句、执行 ID/Run ID（工作台内可见）、
期望行为和实际行为。专业争议写回原审核表，不把界面验收替代专业审核。

【重要】工作台界面改造

1. 这是一个测评中后台，具有实际的生产意义，现状上，交互逻辑混乱，
    a. 目标：现实可用，长期可用，具有生产意义，而非玩具
    b. 期望：
        i. 更加清晰的界面规划：左侧可以新增菜单栏，来负责部分的功能模块，比如总体的计分表就应该和单个测评分开。比如可以做多个二级三级页面，期望一级展示所有问题，进入二级展示单个问题，二级有多个功能，甚至于说新开执行，到三级页面进行单个执行的操作
        ii. 页面整体使用并非只能自上而下排列，也期望能够做一些左右布局，比如前后版本对比，甚至于说多个版本对比横向排开，更符合习惯
        iii. 作为中后台系统一定要有充分的兜底意识
        iv. 作为中后台系统，字段为空，字段异常，查询报错一定会经常出现，要具备良好的可读性。告诉用户是哪个字段没填，导致无法提交表单？无法查询？现在核心问题是用户很难意识到自己哪里输入的不对
        v.